




Primeiros passos em Data Science

Cássia Sampaio, Msc.

O que é IA?

O que é IA





AI

Artificial Intelligence

Inteligência
artificial

de filosofia, algoritmos para resolução de
problemas, probabilidade, lógica,
à robótica


O que é IA



O que é IA

 TensorFlow

PYTORCH




O que é IA



Hugging Face

mesma coisa com muito mais dados,
mais redes neurais,
vem de grandes modelos de linguagem
(LLMs)
N >= 1 trilhão



Como fazer a máquina
“aprender”?



Como fazer a máquina “aprender”?

Dados

email_1 - é spam
email_2 - não é spam
email_3 -



Como fazer a máquina “aprender”?

Dados

email_1 - é spam
email_2 - não é spam
email_3 -


Resultado

email_1 - é spam
email_2 - não é spam
email_3 - **é spam**


Como fazer a máquina “aprender”?



Como fazer a máquina “aprender”?




Como fazer a máquina “aprender”?







Como fazer a máquina “aprender”?



Como fazer a máquina “aprender”?




Como fazer a máquina “aprender”?







Como fazer a máquina “aprender”?





Como fazer a máquina “aprender”?




Como fazer a máquina “aprender”?











E IA Generativa?






Apenas decodificador
(decoder only)



Apenas decodificador
(decoder only)



feito com transformadores

Supervised Fine Tuning

Reinforcement Learning
from Human Feedback

Vamos fazer Data Science na prática?

[Github do projeto](#)

[Google Colab](#)

[Repositório UCI](#)



Pergunta

Uma mulher grávida de uma área afastada da central está em alto risco e precisa de cuidados?

Review and Analysis of Risk Factor of Maternal Health in Remote Area using the Internet of Things (IoT)

Marzia Ahmed¹, Mohammad Abul Kashem¹, Mostafijur Rahman², Sabira Khatun³

¹Department of computer science and engineering, Dhaka University of Science and Technology, Gazipur, Dhaka.

²Department of Software Engineering, Daffodil International University, Bangladesh.

³Faculty of Electrical and Electronics Engineering, University Malaysia Pahang, Malaysia.
ahmed.marzia32@gmail.com

Abstract. IoT is the greatest ingenious innovation in the modern era, which can exploit also in mission-critical like the healthcare industry. This paper demonstrates effective monitoring of pregnant women mostly in a rural area of a developing country, with the help of wearable sensing enabled technology, which also notifies the pregnant women and her family about the health conditions. There are many researchers have been researched to reduce the maternal and fetal mortality but the mortality rate is not reducing, where it should be in zero tolerance. This research intended to use machine learning algorithms for discovering the risk level on the basis of risk factors in pregnancy. In this research, an existing dataset (Pima-Indian-diabetes dataset) has been used for the analysis of risk factor and comparison of some machine learning algorithm shows that Logistic Model Tree (LMT) gives the highest accuracy in case of classification and prediction of the risk level. Regardless, few selected pregnant women's data has been collected (through IoT enabled devices) and the same process also applied for this dataset also by using LMT. Comparison results show that the prediction of risks is the same for the existing and real dataset.



Google Colab

Caderno ou notebook online
Cada espaço é chamado de célula
Podemos ter células de texto ou código

Dá para executar o código e ver a saída na hora



The screenshot shows a Google Colab notebook titled "analise_exploratoria_risco_maternal.ipynb". The interface includes a menu bar with "File", "Edit", "View", "Insert", "Runtime", "Tools", and "Help". Below the menu is a toolbar with "Commands", "+ Code", "+ Text", and "Run all". The notebook content is organized into sections with expandable arrows. The first section, "Breve análise exploratória dos dados", contains a text cell explaining the purpose of the exploratory analysis. The second section, "Visualizando valores e exibindo algumas medidas dos dados", contains three code cells. The first code cell imports pandas as pd. The second code cell defines a URL for a CSV file. The third code cell reads the CSV file into a DataFrame.

```
[2] ✓ 2s 1 import pandas as pd

[3] ✓ 0s 1 # conseguimos puxar os dados por URL pegando o link raw do github
      2 url = "https://raw.githubusercontent.com/cassiasamp/build_with_ai_ws/refs/heads/main/dados/dados_tratados.csv"

[4] ✓ 0s 1 df = pd.read_csv(url)
```



Passo a passo

0. Carregar dados



```
1 import pandas as pd
```



```
1 url = "https://raw.githubusercontent.com/cassiasamp/build_with_ai_ws/refs/heads/main/dados/dados_originais.csv"  
2 df = pd.read_csv(url)
```

Passo a passo

1. Explorar dados

1 df.head()

	Age	SystolicBP	DiastolicBP	BS	BodyTemp	HeartRate	RiskLevel
0	25	130	80	15.0	98.0	86	high risk
1	35	140	90	13.0	98.0	70	high risk
2	29	90	70	8.0	100.0	80	high risk
3	30	140	85	7.0	98.0	70	high risk
4	35	120	60	6.1	98.0	76	low risk



Passo a passo

2. Preparar dados

```
1 df.columns = ['idade', 'sistolica', 'diastolica', 'glicemia', 'temperatura', 'batimentos', 'risco']
```

```
1 df.head()
```

	idade	sistolica	diastolica	glicemia	temperatura	batimentos	risco
0	25	130	80	15.0	98.0	86	high risk
1	35	140	90	13.0	98.0	70	high risk
2	29	90	70	8.0	100.0	80	high risk
3	30	140	85	7.0	98.0	70	high risk
4	35	120	60	6.1	98.0	76	low risk

Passo a passo

2.1. Preparar dados

```
1 df['risco'].unique()
```

```
array(['high risk', 'low risk', 'mid risk'], dtype=object)
```

```
1 dict_risco = {'high risk': 2, 'mid risk': 1, 'low risk': 0}  
2 df['risco'] = df['risco'].map(dict_risco)
```

```
1 df.head()
```

	idade	sistolica	diastolica	glicemia	temperatura	batimentos	risco
0	25	130	80	15.0	98.0	86	2
1	35	140	90	13.0	98.0	70	2
2	29	90	70	8.0	100.0	80	2
3	30	140	85	7.0	98.0	70	2
4	35	120	60	6.1	98.0	76	0



Passo a passo

2.2. Dividir entre características (X) e rótulos (y)

```
1 y = df['risco']  
2 X = df.drop('risco', axis=1)
```

```
1 X.head()
```

	idade	sistolica	diastolica	glicemia	temperatura	batimentos
0	25	130	80	15.0	98.0	86
1	35	140	90	13.0	98.0	70
2	29	90	70	8.0	100.0	80
3	30	140	85	7.0	98.0	70
4	35	120	60	6.1	98.0	76

```
1 y.head()
```

	risco
0	2
1	2
2	2
3	2
4	0

dtype: int64



Passo a passo

2.3. Dividir entre treino e teste

```
1 from sklearn.model_selection import train_test_split
```

```
1 SEED = 42
```

```
1 X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.2, random_state=SEED)
```

```
1 X_treino.shape, X_teste.shape, y_treino.shape, y_teste.shape
```

```
((811, 6), (203, 6), (811,), (203,))
```



Passo a passo

2.4. Standardizar dados (“nivelar” as medidas diferentes)

```
1 from sklearn.preprocessing import StandardScaler
```

```
1 standard = StandardScaler()
```

```
1 X_treino_st = standard.fit_transform(X_treino)
2 X_teste_st = standard.transform(X_teste)
```

sem fit para teste

```
1 X_treino_st[:10]
```

```
array([[ 0.01586892,  0.3596051,  0.26018219,  0.06867785,  1.65272892,
         0.19541766],
       [-0.50789785,  0.90037968, -0.46517963, -0.56360093, -0.50034961,
        -0.5310165 ],
       [ 0.16551657,  0.3596051,  0.98554401, -0.56360093, -0.50034961,
        -0.5310165 ],
       [ 0.09069275,  0.3596051, -1.19054145, -0.80446904, -0.50034961,
         0.19541766],
       [ 0.38998805, -0.72194407, -1.19054145,  1.87518866, -0.50034961,
         0.67970709],
       [ 0.01586892,  0.3596051, -0.10249872, -0.59370944, -0.50034961,
        -0.5310165 ],
       [ 1.51234541,  1.44115426,  0.26018219, -0.62381796, -0.50034961,
        -0.5310165 ],
       [ 0.76410717,  2.52270342,  1.71090582,  3.07952919, -0.50034961,
         0.31649002],
       [ 0.38998805,  0.3596051,  0.26018219, -0.56360093, -0.50034961,
         0.43756238],
       [-0.13377872, -1.26271865, -1.19054145, -0.47327539, -0.50034961,
         0.92185181]])
```

deixar com média 0 e desvio padrão 1



Passo a passo

3. Criar um modelo (e um modelo *baseline*)

Dummy (*baseline*)

```
1 # iremos usar o classificador "bobo" do scikit learn que preve sempre a classe mais frequente de y
2 from sklearn.dummy import DummyClassifier
```

```
1 dc = DummyClassifier(strategy='most_frequent', random_state=SEED)
2 dc.fit(X_treino_st, y_treino)
```



```
▼ DummyClassifier ⓘ ⓘ
DummyClassifier(random_state=42, strategy='most_frequent')
```

Qual modelo usar?





Gráfico de pares (pairplot) de características (features)
os pontos estão com cores de acordo com risco alto, baixo e médio



Fronteiras de decisão de diferentes classificadores do Scikit-learn (é uma intuição, varia dependendo dos dados)
os números na parte inferior direita são o quanto a classificação acertou no geral (acurácia)



Passo a passo

3.1. Criar um modelo (e um modelo *baseline*)

```
1 from sklearn.ensemble import RandomForestClassifier
```

```
1 rfc = RandomForestClassifier(random_state=SEED)
```

```
1 rfc.fit(X_treino_st, y_treino)
```

```
▼ RandomForestClassifier ⓘ ⓘ  
RandomForestClassifier(random_state=42)
```

RFC



Passo a passo

4. Avaliar (e salvar) modelo

Dummy

```
1 # aqui o score retorna a acurácia que é quanto o modelo acertou
2 # em treino
3 dc.score(X_treino_st, y_treino)
```

0.40197287299630086

```
1 # e em teste
2 dc.score(X_teste_st, y_teste)
```

0.39408866995073893

RFC

```
1 # acurácia de treino
2 rfc.score(X_treino_st, y_treino)
```

0.935881627620222

```
1 # acurácia de teste
2 rfc.score(X_teste_st, y_teste)
```

0.8078817733990148

Passo a passo

4.2. Avaliar (e salvar) modelo

```
1 from sklearn.metrics import classification_report, confusion_matrix
```

```
1 preds = rfc.predict(X_teste_st)
```

```
1 cr = classification_report(y_teste, preds)
```

```
1 print(cr)
```

	precision	recall	f1-score	support
0	0.86	0.75	0.80	80
1	0.74	0.84	0.79	76
2	0.87	0.85	0.86	47
accuracy			0.81	203
macro avg	0.82	0.81	0.82	203
weighted avg	0.81	0.81	0.81	203


Passo a passo

4.3. Avaliar (e salvar) modelo

```
1 cm = confusion_matrix(y_teste, preds)
```

```
1 import seaborn as sns
```

```
1 sns.heatmap(cm, annot=True);
```





Passo a passo

4.4. Avaliar (e salvar) modelo

```
1 import pickle as pk
```

```
1 pk.dump(rfc, open('rfc.pkl', 'wb'))
```



```
1 modelo = pk.load(open('rfc.pkl', 'rb'))
```

```
1 modelo.score(X_teste_st, y_teste)
```

```
0.8078817733990148
```



Links

[Github do projeto](https://github.com/cassiasamp/build_with_ai_ws)

https://github.com/cassiasamp/build_with_ai_ws

[Google Colab](https://colab.research.google.com/)

<https://colab.research.google.com/>

[Repositório UCI](https://archive.ics.uci.edu/dataset/863/maternal+health+risk)

<https://archive.ics.uci.edu/dataset/863/maternal+health+risk>



Receita de primeiro projeto de DS

Escolha um tema e um dataset: risco de saúde maternal

Defina uma pergunta para responder: uma mulher grávida está em alto risco e precisa de cuidados?

Entenda o problema que está resolvendo: problema de classificação entre alto, médio e baixo risco

Veja o que você precisa fazer com os dados para colocar no modelo: os dados têm padrão? os tipos de dados são muito diferentes? explore os dados

Execute o modelo: por exemplo, modelo de floresta aleatória (Random Forest) do sklearn com parâmetros padrão

Entenda os resultados: o que o modelo classificou certo e o que classificou errado

Você já tem um **primeiro** projeto!

Conteúdos iniciais

Livros em inglês

[Python Data Science Handbook](#)




[Python Machine Learning Raschka](#)

[Pattern Recognition do Bishop](#)

Githubs em português

[Github do Fernando Masanori](#)

[Github de Data Science das PyLadies](#)





Cursos online

Coursera

[Data Science Courses](#)

Udacity

[Data Science Courses na Udacity](#)

Datacamp

[Data Science for Everyone](#)

Udemy

[Data Science da Hekima](#)

Leia sempre as ementas do curso para ver se o conteúdo faz sentido,
Priorize os cursos gratuitos e veja se tem legendas em português.

Repositórios de dados mais comuns

Em inglês

[Kaggle Datasets](#) (tomar cuidado com dados sintéticos e verificar a fonte dos dados)

[Repositório da UCI](#)

[HuggingFace Datasets](#)


Em português

[Portal de Dados Abertos](#)

Como encontrar dados?

Geralmente fazendo pesquisas do tipo **assunto + dataset** em um buscador

Dá para **coletar dados** também



[site do livro \(em inglês\)](#)

Muito obrigada!

Contatos

 @cassiasamp

 @cassiasamp

 @cassiasamp

